PLANO DE GERENCIAMENTO DOS DADOS: FONTE DA BASE, DICIONÁRIO DE VARIÁVEIS E PRIMEIRAS DESCOBERTAS

Projeto: Na Esquina — Plataforma Digital de Geolocalização e Conexão para o Comércio de Comida de Rua

Disciplina: Gerência de Projetos de Software (2026.2)

Responsável pelo Bloco: Luiz Dias (Engenheiro/Cientista de Dados — Líder CRISP-DM)

Data de Atualização: 4 de outubro de 2026

1. MAPEAMENTO E FONTE DA BASE (BLOCO F)

A base de dados do Na Esquina sustenta a Competência 1 da disciplina e a decisão de produto da plataforma. Seguindo o ciclo CRISP-DM, esta seção descreve de onde vêm os dados, por que são relevantes e qual é o volume previsto, respondendo à pergunta central do projeto: onde, quando e o que os ambulantes vendem, para orientar consumidores e vendedores.

1.1 Fontes de dados

- **Fonte primária — Pesquisa de campo:** coleta ativa de 50 registros amostrais de ambulantes locais por formulário padronizado, preenchido em visita presencial, com latitude/longitude capturadas via GPS do smartphone, categoria alimentar, faixa média de preço, dias e horários de pico. É a única fonte que descreve o vendedor invisível para as grandes plataformas.
- **Fonte primária — Banco de dados do próprio aplicativo:** o app já registra os pontos de venda no Supabase (PostgreSQL), nas tabelas restaurantes, categorias e cardapios. Cada cadastro de vendedor gera um registro com coordenadas, categoria, horário de funcionamento e itens de cardápio com preço (dados gerados pelo próprio sistema, aceitos pelo edital).
- **Fonte secundária — DataSebrae / Portal do Empreendedor:** microdados de formalização e adensamento comercial de MEIs do setor alimentício, usados para contextualizar o tamanho do público-alvo.
- **Fonte secundária — Bases abertas municipais:** logradouros, polos gastronômicos e feiras livres licenciadas, usados para a camada de referência do painel analítico (RF08) e para a validação cruzada das coordenadas coletadas.

1.2 Relevância, volume e estrutura

Aspecto	Descrição
Relevância	Responde ao problema de assimetria de informação e ao posicionamento empírico dos ambulantes (Declaração de Escopo, Seção 2): sem saber onde e quando há oferta, o consumidor não decide e o vendedor não escolhe bem o ponto.
Volume-alvo	Mínimo de 50 registros georreferenciados válidos (critério de aceitação do pacote EAP 1.2.1), mais a camada de referência de feiras livres e polos.
Estrutura	Uma linha por ponto de venda (tabela restaurantes), ligada à tabela categorias por categoria_id e aos itens de cardápio (tabela cardapios) por restaurante_id. Seis variáveis analíticas, mais a variável derivada polo_urbano (Seção 2).
Formato e armazenamento	Exportação das tabelas do Supabase em CSV (consulta SQL anexa), tratamento em script e recarga da base tratada no mesmo banco na Sprint 2.
Privacidade (LGPD)	Dados pessoais de cadastro (e-mail, telefone, senha) ficam fora da base analítica; ver Seção 2.1. Na análise, os únicos identificadores são o nome fantasia comercial e as coordenadas do ponto de venda, em conformidade com o RNF03.

1.3 Plano de contingência de amostragem

Caso a coleta direta enfrente resistência dos ambulantes ou não atinja a meta de 50 cadastros no prazo, a base será complementada com microdados públicos municipais e com a geocodificação de feiras livres licenciadas, conforme previsto na Declaração de Escopo (Seção 6.1). Essa decisão será registrada no controle de mudanças, indicando a proporção de registros de cada origem.

2. DICIONÁRIO DE VARIÁVEIS (BLOCO F)

A tabela lista os campos analisados com o nome real da coluna no banco do aplicativo (Supabase), seus tipos, descrições e valores esperados. As variáveis horario_pico, faixa_preco e polo_urbano são derivadas na etapa de preparação; o preço no cardápio é armazenado como texto e precisa ser convertido para número.

Variável (coluna)	Tipo	Descrição	Domínio / formato
nome (restaurantes)	Texto	Nome fantasia do ponto de venda, único identificador público do vendedor.	Texto livre
latitude (restaurantes)	Numérico (decimal)	Coordenada do ponto, capturada via GPS ou ajuste manual do pin.	Graus decimais; dentro do perímetro urbano analisado
longitude (restaurantes)	Numérico (decimal)	Coordenada complementar à latitude.	Graus decimais; dentro do perímetro urbano analisado
categoria_id → categorias.nome	Categórico	Categoria culinária do ponto, usada nos filtros e na escolha do pin do mapa.	Valores da tabela categorias (ex.: bebidas, doces, hambúrguer, pizza, salgados)

Variável (coluna)	Tipo	Descrição	Domínio / formato
hora_inicio e hora_fim (restaurantes)	Texto (hora)	Horário de atendimento informado pelo vendedor. A faixa de pico (horario_pico) é derivada a partir dele e, na pesquisa de campo, do formulário.	Formato HH:MM; pico em 11h-14h, 14h-17h ou 17h-20h
preco (cardapios) → faixa_preco	Texto → categórico ordinal	Preço de cada item do cardápio. A faixa de preço do ponto (faixa_preco) é derivada da mediana dos preços de seus itens.	Até R$ 8; R$ 8-15; R$ 15-25
polo_urbano (derivada)	Categórico	Polo de fluxo mais próximo do ponto, para o painel de densidade (RF08).	Definido na preparação, a partir da base municipal

2.1 Dados pessoais do cadastro e justificativa (LGPD)

Além das variáveis analíticas, o aplicativo coleta dados pessoais no cadastro de conta (tabela usuarios e serviço de autenticação do Supabase) e no cadastro da loja. Esses campos existem para operar o sistema, não para análise: eles ficam fora da base analítica e do painel (RF08), e a consulta de exportação do Bloco F não os inclui. A tabela explica a finalidade de cada um, em linha com o princípio da necessidade da LGPD (coletar apenas o mínimo para a finalidade).

Variável (coluna)	Obrigatório?	Por que é coletada (finalidade)	Tratamento e proteção
email (usuarios / Auth)	Sim	Identifica a conta e é o login do usuário (também via Gmail). Serve para recuperação de acesso e contato sobre a conta.	Fora da base analítica e das exportações do Bloco F.
senha (Auth)	Sim, no cadastro manual (mín. 6 caracteres)	Autentica o usuário e protege os dados do vendedor e do cliente (RF01).	Gerida pelo serviço de autenticação do Supabase, armazenada com hash; nunca aparece na tabela usuarios nem nas exportações.
telefone (usuarios)	Não (opcional; informar com DDD)	Permite contato sobre a conta e, para o vendedor, facilita o atendimento.	Guardado apenas com dígitos; fora da base analítica.
whatsapp (restaurantes)	Sim, para a loja	Canal de contato do consumidor com o ambulante, sem intermediação. Também impede dois cadastros com o mesmo número.	Informado conscientemente pelo vendedor; fora da base analítica.
data_nasc (usuarios)	Não (opcional)	Complementa o perfil e pode apoiar análises de faixa etária agregadas, nunca individuais.	Usada só de forma agregada, se usada.
nome, tipo_usuario, avatar_url	nome sim; demais definidos no cadastro	Nome identifica o usuário; tipo_usuario separa vendedor de cliente; avatar_url é a foto de perfil escolhida.	Foto enviada voluntariamente ao armazenamento (storage) do Supabase.

Variável (coluna)	Obrigatório?	Por que é coletada (finalidade)	Tratamento e proteção
cpf (cadastro de conta)	Sim	Identifica de forma única a pessoa por trás da conta, evitando contas duplicadas ou falsas e dando responsabilização ao vendedor que divulga ponto, cardápio e Pix na plataforma. Também apoia a verificação de que o vendedor é uma pessoa real quando o MEI é consultado nas bases públicas.	Dado privado: nunca exibido a outros usuários nem em tela pública (RNF03). Excluído da base analítica, do painel e das exportações do Bloco F. Acesso restrito à autenticação e à administração.

Base legal sugerida: a execução do serviço contratado pelo usuário e a prevenção a fraudes e a contas falsas (e-mail, senha, nome e CPF, que são obrigatórios) e o consentimento para os dados opcionais (telefone e data de nascimento). Como o CPF é um identificador de alto valor, a minimização se aplica ao uso: ele é coletado apenas para a verificação de identidade e não serve a nenhuma análise. A equipe deve validar esse enquadramento com o professor, pois este documento não substitui orientação jurídica.

3. QUALIDADE E TRATAMENTO PLANEJADO (BLOCO F)

Antes de qualquer análise, a base passa por um pipeline de preparação (script documentado, pacote EAP 1.2.3). A tabela resume os problemas esperados em dados coletados em campo e a regra aplicada a cada um.

Problema esperado	Regra de tratamento	Justificativa
Coordenadas nulas	Descartar o registro ou recoletar o ponto em campo.	Sem coordenada o ponto não aparece no mapa nem no painel.
Outliers de GPS	Descartar pontos fora do perímetro urbano analisado e validar com a base municipal.	Erros de GPS distorcem a densidade e os marcadores.
Duplicatas	Remover registros com mesmo nome fantasia e coordenadas muito próximas.	Evita contar duas vezes o mesmo ambulante.
Categorias inconsistentes	Normalizar grafias para as 5 categorias oficiais do filtro.	Garante a coerência entre dados e o filtro RF06.
Horários e preços livres	Converter respostas livres para as faixas do dicionário.	Permite comparar categorias e polos.

4. PRIMEIRAS DESCOBERTAS E GRÁFICOS (BLOCO F)

> **Nota de transparência:** os valores, gráficos e percentuais da Seção 4 foram calculados sobre uma amostra simulada de 50 registros, gerada apenas para estruturar o Bloco F antes da consolidação da base de campo. Conforme a regra do edital, dados simulados são aceitos desde que justificados. As categorias do exemplo são ilustrativas. Antes do Checkpoint de 06/10/2026, esta amostra deve ser

> substituída pela exportação real das tabelas do Supabase (consulta SQL anexa) e os gráficos e textos de interpretação devem ser regerados.

4.1 Distribuição por categoria de alimento

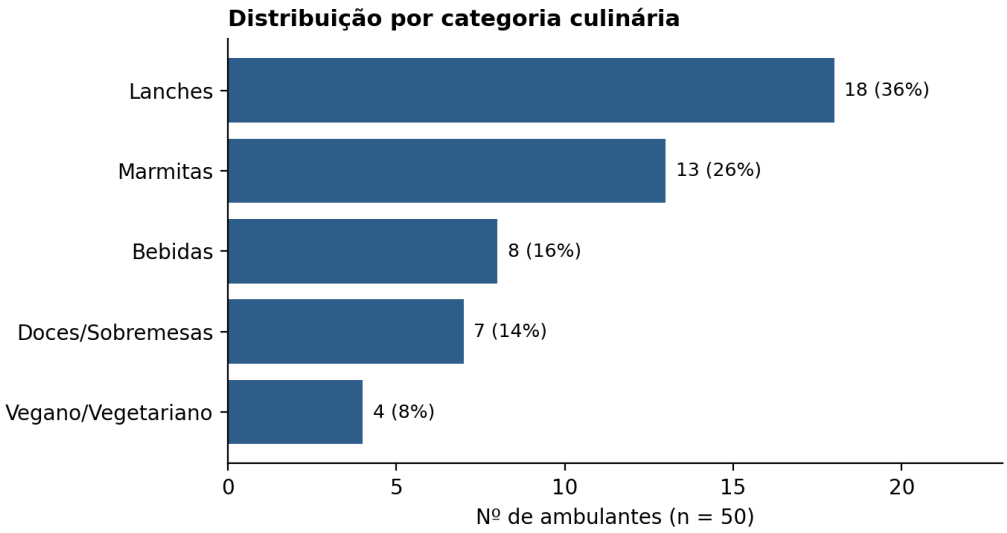


Gráfico 1 — Ambulantes por categoria culinária (amostra simulada, n = 50)

Lanches (36%) e Marmitas (26%) somam 62% dos pontos, enquanto Vegano/Vegetariano representa apenas 8%. Isso indica uma oferta concentrada em refeições rápidas e uma lacuna de opções específicas, que é exatamente o tipo de busca que o filtro por segmento (RF06) precisa atender.

4.2 Concentração geográfica

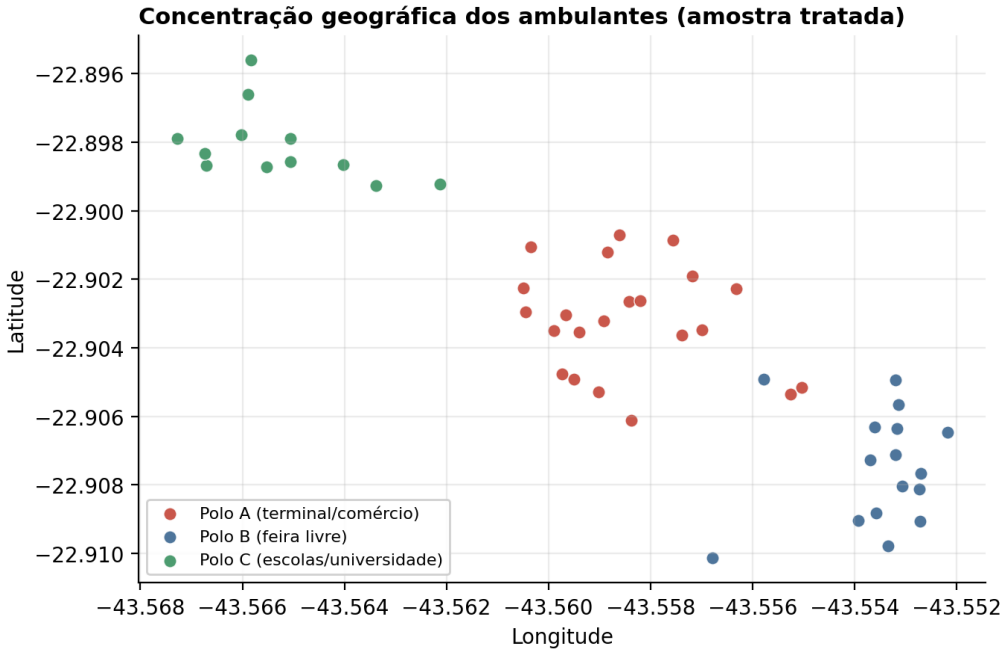


Gráfico 2 — Localização dos ambulantes por polo urbano (amostra simulada, n = 50)

Os pontos se agrupam em três polos: terminal/comércio (22 pontos, 44%), feira livre (16, 32%) e escolas/universidade (12, 24%). Há áreas vazias entre os polos, que o painel de densidade pode apontar como oportunidade de posicionamento para o vendedor.

4.3 Como os dados embasam a solução

Na amostra, 58% dos pontos têm pico entre 11h e 14h e 36% entre 17h e 20h, o que sugere dois momentos de uso do aplicativo: o almoço e o fim do dia. A faixa de preço mais comum é R$ 15-25 (42%), associada às marmitas. A tabela relaciona cada achado a uma decisão de projeto.

Achado	Decisão de produto / projeto
Oferta concentrada em Lanches e Marmitas	Manter as 5 categorias no filtro (RF06), com Lanches e Marmitas em destaque e a opção Vegano/Vegetariano visível para a demanda específica.
Agrupamento em polos, com áreas vazias	Priorizar no painel analítico (RF08 / US08) a comparação entre densidade de ambulantes e polos de fluxo, para apoiar a escolha do ponto.
Pico de movimento no almoço e no fim da tarde	Destacar o botão "Aberto Agora" (RF02) nesses horários e usar a faixa de pico como informação no painel do ponto (RF07).
Faixas de preço distintas por categoria	Exibir a faixa de preço no detalhamento do estabelecimento, ajudando o consumidor a decidir antes de ir ao ponto.

5. PRÓXIMOS PASSOS DO BLOCO F

- Exportar a base real do Supabase com a consulta SQL anexa, somar os registros da pesquisa de campo e substituir a amostra simulada, regenerando os gráficos e revisando os textos da Seção 4.
- Executar e documentar o script de limpeza (pacote EAP 1.2.3) e registrar quantos registros foram descartados em cada regra.
- Cruzar a base tratada com a camada municipal de feiras livres e polos para validar as coordenadas e calcular o índice de densidade de oferta vs. demanda.
- Carregar a base tratada no Supabase na Sprint 2 (semana de 19/10 a 23/10/2026), conectando-a ao painel analítico da Sprint 3.